

RÉSUMÉ

Contexte

La sous-nutrition reste un défi majeur de santé publique au Cameroun. Les analyses épidémiologiques traditionnelles évaluent souvent les indicateurs de croissance de manière isolée. Cette étude introduit un cadre intégré combinant des statistiques de sondage robustes et l'apprentissage automatique pour modéliser la coexistence des dimensions de la sous-nutrition via l'**Indice Composite de l'Échec Anthropométrique (ICEA)**.

Méthodes

Les données des enfants de moins de 5 ans de l'**Enquête Démographique et de Santé (EDS)** du Cameroun 2018 ont été analysées. Pour traiter la coexistence structurelle, l'**Analyse des Correspondances Multiples (ACM) de Benzécri** a permis de calculer les poids optimaux du retard de croissance, de l'émaciation et de l'insuffisance pondérale afin de construire une variable cible **ICEA** unifiée. La modélisation épidémiologique a été réalisée via des modèles linéaires généralisés (GLM) pondérés, utilisant des estimateurs de variance de type **Sandwich** robustes aux grappes pour corriger le plan de sondage complexe (*poids_analytique*) et la corrélation intra-classe au niveau des grappes de l'EDS, identifiées sous le code officiel DHS **v001** (*numerogruppe*). En parallèle, un pipeline de Machine Learning robuste aux grappes a été déployé avec un test de résistance (*Stress Test*) sur 15 % de grappes **v001** totalement isolées. Six algorithmes ont été mis en compétition, et le meilleur, **CatBoost** Classifier a été optimisé par une recherche aléatoire avec validation croisée de type **GroupKFold**.

Résultats

Le modèle GLM pondéré a corrigé les erreurs initiales de spécification fonctionnelle, validant le **Linktest de Pregibon** (p-value de $\hat{Z}^2 = 0,3387$). Les rapports de chances ajustés (**AOR**) ont identifié le quintile de richesse, l'âge de l'enfant (effet quadratique), l'instruction maternelle et l'index synergique **WASH** (eau et toilettes améliorées) comme les principaux déterminants structurels. Lors de la phase de Machine Learning, CatBoost a émergé en tête avec une aire sous la courbe **ROC (ROC AUC)** robuste de 0,7442 sur les données de test. Le **Stress Test** sur les grappes **v001** inconnues a confirmé une stabilité de généralisation exceptionnelle (Train AUC : 0,7346 vs Stress AUC : 0,7278, soit un delta de 0,0068), neutralisant le surapprentissage spatial. L'importance par permutation a corroboré l'impact prédictif global dominant de la richesse et de l'âge. La marginalisation clinique finale a décodé avec succès les probabilités de risque pour chaque sous-phénotype de l'OMS.

Conclusions

La synergie entre l'économétrie pondérée et l'apprentissage automatique régularisé par arbres offre un outil de diagnostic valide et généralisable pour la santé publique. Ces résultats tracent des voies d'action précises pour le déploiement d'interventions nutritionnelles ciblées au Cameroun.

Mots-clés : Sous-nutrition infantile, Indice Composite de l'Échec Anthropométrique (ICEA), Enquête Démographique et de Santé (EDS), Code DHS v001, Modèle linéaire généralisé pondéré, Analyse des Correspondances Multiples de Benzécri, CatBoost Classifier, Validation croisée robuste aux grappes, Stress testing, Cameroun.